


DATA SCIENCE · PROYECTO FINAL?

Credit Card Fraud Detection

Machine Learning · Deep Learning · SHAP · GridSearchCV · Business Score



164,820/21'000,000

transacciones

16.67%

tasa de fraude (5:1)

Threshold 0.35

Red Neuronal optimizado


Fuente, Estructura y Hallazgos del EDA

Fuente del Dataset


HuggingFace ·
CiferAI/Cifer-Fraud-Detection-Dataset-AF

Dataset original	21,000,000 registros
Dataset de trabajo (tras submuestreo)	164,820 registros
Legítimas	137,350 (83.33%)
Fraudes	27,470 (16.67%)
Ratio muestreo	5:1 (no-fraud submuestreado)
Features originales	10 → 7 (tras limpieza)
Train / Test	131,856 / 32,964 (80/20)

Balance de Clases



Feature Importance (Random Forest)



Pipeline de Preprocesamiento

1

Carga HuggingFace

```
load_dataset()  
→ token  
HF_API_KEY  
→ ratio 5:1  
164,820 registros
```

2

Drop columnas

```
nameOrig  
nameDest  
isFlaggedFraud  
→ 10 → 7 features
```

3

Encoding

```
LabelEncoder  
sobre: type  
→ texto a int  
(TRANSFER,  
CASH...)
```

4

Split 80/20

```
train: 131,856  
test: 32,964  
stratify=y  
random_state=42
```

5

SMOTE + Scaler

```
SMOTE solo  
en train  
StandardScaler  
fit en train
```



Los 4 Modelos — Configuración y Resultados

Logistic Regression

Baseline

F1

0.2483

Recall

48.43%

CV F1:

0.3850 ± 0.043

⚙️ max_iter=1000

⚙️ Datos escalados

⚙️ random_state=42

- Alta FP (13,276)
- Rápida e interpretable

Random Forest

Mejor CV: 0.7857

F1

0.2516

Recall

28.80%

CV F1:

0.7857 ± 0.073

⚙️ GridSearchCV (F1, cv=3)

⚙️ max_depth: [10, 20]

⚙️ n_estimators: [100]

- Mayor accuracy (71.45%)
- Feature importance nativa

XGBoost

Gradient Boosting

F1

0.2394

Recall

39.50%

CV F1:

0.6564 ± 0.100

⚙️ n_estimators=200

⚙️ learning_rate=0.05

⚙️ max_depth=6, logloss

- Alta varianza CV (±0.10)
- Segundo en F1-test

Red Neuronal

🏆 Ganador (Técnico + Negocio)

F1

0.2790

Recall

83.16%

CV F1:

0.6240 ± 0.007

⚙️ Threshold: 0.35 (optimizado)

⚙️ EarlyStopping (patience=5)

⚙️ 37/50 epochs

- Recall 83.16% → 4,569 detectados
- Std CV mínima: 0.007

Ranking Técnico vs. Impacto de Negocio

Métricas Técnicas (test set)


Modelo	Accuracy	Precision	Recall	F1-Score	AUC-ROC
Red Neuronal	28.35%	16.76%	83.16%	0.2790	0.5035
Random Forest	71.45%	22.34%	28.80%	0.2516	0.5794
Logistic Regression	51.13%	16.70%	48.43%	0.2483	0.5024
XGBoost	58.18%	17.18%	39.50%	0.2394	0.5124

Ranking de Negocio — TP – (FP×0.05) – (FN×5)

Modelo	Business Score	Fraudes Detectados	Fraudes Perdidos	Clientes Afectados
Red Neuronal	-1,190.75	4,569	925	22,695
Logistic Regression	-12,167.8	2,661	2,833	13,276
XGBoost	-14,973.1	2,170	3,324	10,462
Random Forest	-18,252.9	1,582	3,912	5,498

Arquitectura, Threshold Sweep y SHAP Values

Arquitectura MLP



Config:


Loss: **BinaryFocalCrossentropy** Optimizer: **Adam**
 Epochs: **37/50 (EarlyStopping)** Threshold: **0.35 (optimizado)**
 Callbacks: **EarlyStopping · ReduceLROnPlateau**

Threshold Sweep → ¿por qué 0.35?

Threshold	F1	Recall	Precision
0.001	0.279	0.999	0.167
0.10	0.279	0.980	0.167
0.20	0.280	0.950	0.168
0.35	0.279	0.832	0.168
0.40	0.270	0.790	0.168
0.50	0.207	0.484	0.167

SHAP Values — Explicabilidad de la Red Neuronal


```
shap.Explainer(nn_model, X_sample[:500])
```




→ Confirma que los saldos de cuenta son los predictores más importantes

Cross-Validation (5-fold), Overfitting y Matrices de Confusión

Cross-Validation F1 Promedio (5-fold)



Business Score (mayor = mejor)



Overfitting Analysis — Red Neuronal

Train AUC: 0.6606 | Val AUC: 0.6632 | Gap: 0.0026 → ✓ Sin overfitting

Matriz — Red Neuronal (threshold=0.35)

TN: 4,775 | FP: 22,695 | FN: 925 | TP: 4,569

¿Qué aprendimos?



01

El balance de datos influye directamente en los resultados: Trabajamos con un dataset balanceado mediante un ratio 5:1 entre transacciones legítimas y fraudes, lo que permitió que los modelos aprendieran mejor a identificar casos fraudulentos

02

La Red Neuronal fue el modelo más efectivo: Obtuvo el mejor desempeño tanto a nivel técnico como de negocio, detectando el 83% de los fraudes y generando el menor costo estimado para la empresa.

03

Un buen resultado en entrenamiento no garantiza un buen resultado real: Aunque Random Forest mostró métricas muy altas durante la validación, su rendimiento disminuyó significativamente en datos nuevos, evidenciando problemas de sobreajuste.

04

Los saldos de las cuentas son las variables más importantes: Los análisis de interpretabilidad mostraron que los balances antes y después de la transacción son los factores que más influyen en la detección de fraude.

05

Detectar un fraude es más importante que evitar una falsa alarma: El costo de no detectar un fraude es mucho mayor que el de revisar una transacción legítima. Por esta razón, se priorizó el Recall, favoreciendo modelos capaces de identificar más fraudes reales.